

基于深度学习的接触矩阵处理实践方案

本次实践基于深度学习技术。以 Micro-C 接触矩阵为输入，独立完成未知染色质结构发现等任务的方案设计、实现与验证。

一、实践概述

深度学习技术已广泛应用于图像识别、自然语言处理与生命科学等领域，**三维基因组数据分析**是其中之一。

项目	内容
实践名称	基于深度学习的新结构发现系统
分组方式	2-3 人一组
核心问题	给定 Micro-C 接触矩阵，如何自动、可解释地发现未被注释的染色质结构
核心产出	代码、讲解视频、实验报告

成员分组



<https://365.kdocs.cn/l/cd3YPxLwxXm1>

二、实践目标


掌握深度学习技术，即理解并运用自编码器、卷积网络、图神经网络等模型，完成接触矩阵的读取、归一化、可视化，以及候选检测、结构表征、聚类等环节的实现。

培养逻辑思维，即把一个开放问题拆解为可操作的定义与步骤，独立设计技术路线，并论证每一步设计的选择。

三、基础知识背景

3.1 三维基因组：DNA 的空间组织

DNA 在细胞内并非随机伸展，而是折叠成特定的空间结构。线性上相距较远的两个位点，在三维空间中可能相互邻近，这种空间组织会影响基因的转录与调控。




3.2 Hi-C 技术：如何测量三维组织

Hi-C (high-throughput chromosome conformation capture) 用于测量基因组中任意两个位点在三维空间中是否相互靠近。其做法是：先把空间上相互靠近的 DNA 片段固定在一起，再切碎、连接并测序，统计任意两个位点被连在一起的次数。次数越多，说明两个位点在三维空间中越靠近。

Hi-C 的分辨率通常在 0.5–1 kb 量级，难以解析更精细的结构；更精细的结构需借助下文介绍的 Micro-C 技术。

3.3 接触矩阵：数据的载体


上述相互作用次数构成一张对称矩阵，称为接触矩阵，行与列均为基因组位置，矩阵元素为两个位置之间的接触频率。矩阵的分辨率由基因组切分的固定长度决定，常见取值如 2、4、8、16 kb，分辨率越高，矩阵规模越大，计算开销也越大。接触矩阵一般渲染为热图呈现，对角线附近的强信号对应近距离或结构内部的相互作用。



接触矩阵既可视作数值矩阵，交给数值模型处理，也可渲染为图像，交给图像模型处理。这两种视角对应两类深度学习建模方式。

3.4 超高分辨率接触图：Micro-C

Micro-C 是 Hi-C 的改进变体。它改变了切割 DNA 的方式，使片段更短、切割更均匀，分辨率可提高到约 10 bp (Hi-C 为 0.5–1 kb)，从而能观察到 Hi-C 难以分辨的精细结构。本次实践使用的数据为 Micro-C 接触矩阵。




3.5 细菌基因组的三维组织与已知结构类型

在超高分辨率 Micro-C 接触图中，可以识别出三种已知结构类型，作为“已知类型”的参考标签：

结构类型	定位	关键特征
OPCID	高转录操纵子	转录驱动
CHIN	非转录区域	接触簇，由 H-NS 等介导，长约 2 kb
CHID	非转录区域	由多个 CHIN 聚集

OPCID 出现在高转录的基因区域，依赖转录，抑制转录即消失。CHIN 出现在非转录区域，在接触矩阵中表现为对角线附近的接触簇，与 H-NS 等蛋白相关。CHID 由多个 CHIN 聚集而成。

OPCID ($n = 68$) CHIN ($n = 250$)



本次实践要解决的核心问题是：在这些已知类型之外，是否存在尚未被注释的新结构。

3.6 新结构发现：一个开放的计算问题

从接触矩阵中寻找未知结构是无监督问题，没有现成标注，无法用有监督分类直接训练。

需要区分接触量与结构形态。接触量高只说明该区域相互作用频繁，不代表存在特定形态的结构；形态独特的结构也可能接触量并不突出。检测不能只看接触量高低。自编码器可用重建误差判断区域是否偏离背景，卷积网络从矩阵中学习形态，聚类与降维把相似候选归为一类。

大肠杆菌基因组约 4.6 Mb，单个局部窗口可缩放到 64×64 或 128×128，计算量在单机可负担范围内。

四、先修知识与工具

- 编程与基础库：Python、NumPy、pandas、matplotlib
- 机器学习基础：PCA、K-means、HDBSCAN、自编码器、异常检测
- 深度学习基础：卷积网络、图神经网络
- 接触矩阵处理：cooler、cooltools
- 聚类与降维：scikit-learn、umap-learn、hdbscan

五、实验数据与资源



链接：<https://pan.quark.cn/s/bbe1466a855a?pwd=SsJM> 提取码：SsJM 截图保存二维码，扫码获得文件

5.1 接触矩阵数据

接触矩阵以 `.cool` 格式存储，记录基因组各区间两两之间的接触次数，是一个对称稀疏矩阵，只保存非零值。对角线附近的强信号对应线性距离近的位点，偏离对角线的块状或条纹状信号对应三维空间中的结构。


本次实践提供大肠杆菌 MG1655 的 Micro-C 接触矩阵（`.cool` 格式，10 bp 分辨率，环状基因组 4,641,652 bp），用 cooler 库读取，预处理流程为读取、归一化、切窗、渲染。主要数据与用途如下表：

数据	说明	用途
主数据集（37°C 深测 Micro-C）	野生型，两个生物学重复，5–7× 接触深度	检测、聚类、验证
多条件数据集	去除或突变某核质相关蛋白、凝缩蛋白后的接触矩阵	机制验证、差异分析
已知结构注释	已知类型（OPCID / CHIN / CHID）的坐标表	已知类型中心、召回基准、对照

除上表数据外，本次实践还额外提供若干不同条件的接触矩阵（含重复与对照），各条件的生物学意义如下表：

条件	样本名	生物学意义
Δ stpA	DstpA_rep1/rep2	StpA（类 H-NS 核质相关蛋白）缺失
Δ hns Δ stpA	DhnsDstpA_rep1/rep2	H-NS + StpA 双缺失
H-NS 突变	HNS_mut_rep1/rep2	核质相关蛋白 H-NS 突变
FIS 突变	FIS_mut_rep1/rep2	FIS（NAPs）突变
Δ mukB	muk_rep1/rep2	凝缩蛋白（SMC 复合体）缺失
无连接对照	NoLig_rep1	阴性对照（不做连接）
37℃ 固定	37C_37C_fix_rep1	温度/固定对照
室温固定	RT_RT_fix_rep1	温度对照
博来霉素	bleo_rep1/rep2	DNA 双链断裂损伤
新生霉素 25/250	novo25 / novo250	DNA gyrase（拓扑异构酶 II）抑制剂
环丙沙星 0.025/0.25	cipro0025 / cipro025	拓扑异构酶 II 抑制剂
纺锤菌素 20/200	net20 / net200	DNA 小沟结合剂（改变弯曲）

这些条件可用于对照：一个候选结构在不同条件下的存续或改变，可反推其成因，从而解释结构的形成机制。



GSM9678479_HNS_mut_rep2.MG1655.mapq_30.10.cool.gz
GSM9678478_HNS_mut_rep1.MG1655.mapq_30.10.cool.gz
GSM9078281_FIS_mut_rep2.MG1655.mapq_30.10.cool.gz
GSM9078280_FIS_mut_rep1.MG1655.mapq_30.10.cool.gz
GSM8950778_muk_rep2.MG1655.mapq_30.10.cool.gz
GSM8950777_muk_rep1.MG1655.mapq_30.10.cool.gz
GSM8950776_net200.MG1655.mapq_30.10.cool.gz
GSM8950775_net20.MG1655.mapq_30.10.cool.gz
GSM8950774_cipro025.MG1655.mapq_30.10.cool.gz
GSM8950773_cipro0025.MG1655.mapq_30.10.cool.gz
GSM8950772_novo250.MG1655.mapq_30.10.cool.gz
GSM8950771_novo25.MG1655.mapq_30.10.cool.gz
GSM8950770_bleo_rep2.MG1655.mapq_30.10.cool.gz
GSM8950769_bleo_rep1.MG1655.mapq_30.10.cool.gz
GSM8950768_RT_RT_fix_rep1.MG1655.mapq_30.10.cool.gz
GSM8950767_37C_37C_fix_rep1.MG1655.mapq_30.10.cool.gz
GSM8950765_NoLig_rep1.MG1655.mapq_30.10.cool.gz
GSM8950764_DhnsDstpA_rep2.MG1655.mapq_30.10.cool.gz
GSM8950763_DhnsDstpA_rep1.MG1655.mapq_30.10.cool.gz
GSM8950762_DstpA_rep2.MG1655.mapq_30.10.cool.gz
GSM8950761_DstpA_rep1.MG1655.mapq_30.10.cool.gz

5.2 标注数据

本次实践提供已知结构清单与基因组注释。已知结构清单 `structures.csv` 收录 344 个已知局部结构，字段包括类型（CHIN / OPCID / CHID）、染色体、起止坐标、中心与长度等，可用作有监督分类的正样本或“已知 vs 候选”的对照。文件中table4, table5, table6分别为opcid, chin与chid的位置标注

六、实验任务

本次实践要求完成必做与选做各一。必做任务每组均须完成。选做任务每组至少选其一完成。

6.1 必做任务

任务一：已知结构的有监督识别与可解释分析（40分）

任务目标。利用 344 个带类型标签的 CHIN、OPCID、CHID 结构训练识别模型，考察模型能否可靠识别这些结构的形态。识别器可用于任务二，在发现阶段过滤“其实只是已知结构”的候选；对识别器做可解释性分析。

任务要求。样本以已知结构坐标为中心截取局部窗口，模型可用卷积网络（将矩阵作为图像）或图神经网络。评价以分类准确率与混淆矩阵为主。可解释性分析以注意力图或显著性图展示模型关注的区域。可以可视化出部分检测出结构的热力图。

任务的输入与产出如下：

输入

- 接触矩阵，`.cool` 格式，10 bp 分辨率；
- 已知结构清单 `structures.csv`，344 条，含 CHIN / OPCID / CHID 类型标签。

输出

- 训练完成的识别器权重文件（如 `.pt` / `.pth`），附可复现的训练与评估脚本（含随机种子与依赖说明）；
- 留出样本上的分类准确率与混淆矩阵（数值表 + 图）；
- 各结构类型的显著性图或注意力图（PNG）。

若模型对各类结构都能稳定识别，且显著性图显示其关注的是结构本身而非背景密度，即可认为任务完成。

加分项：能根据检测模型设计一个辅助标注工具

任务二：新型染色质结构发现（30分）

任务二要求在已知的 CHIN、OPCID、CHID 三类结构之外，从 Micro-C 接触矩阵中找出可复现的、未被注释的染色质结构。新结构形态未知，无标准标注与正确答案可用，候选的判定与流程的组织需自行设计并论证。

本任务为开放性任务，可以参考的流程包括候选区域发现、结构表征、分组策略与验证四个环节，前三者为方法设计核心，验证环节的要求见输出部分。

候选区域发现

任务目标。从全基因组矩阵中圈定可能含有结构的局部窗口。评分需区分密度异常与形状异常，与背景噪声做区分，本步骤以高召回为目标。

最低实现要求。能够读取 `.cool` 矩阵并完成归一化，实现全基因组的窗口切分；至少实现一种候选打分方法，输出带分数与坐标的候选集；候选集应当能够覆盖已知结构（即已知结构能被召回），否则说明检测环节存在问题。

结构表征

任务目标。把候选窗口的矩阵转换为对形状敏感的固定维度向量，作为分组与判定的基础。

最低实现要求。实现至少一种表征方法，能够把任意候选窗口映射为固定维度的向量；该表征应能把已知结构与随机背景区分开，例如在降维可视化中两者呈现可观察的分离，或用一个简单分类器即可达到明显高于随机的准确率。

分组策略

任务目标。把形态相似的候选聚成若干结构类型，并界定“新结构簇”：成员数达到阈值且不含已知结构。

最低实现要求。实现降维与至少一种聚类算法，能够输出若干候选簇及其成员与中心；能够区分已知结构簇与疑似新结构簇，即把落在已知结构附近的候选标注出来，避免把已知结构误报为新发现。

验证环节以跨生物学重复的复现性为核心：真实结构应在两个独立的生物学重复中均能观察到。

任务的输入与产出如下：

输入

- 37°C 深测序野生型 Micro-C 接触矩阵，`.cool` 格式，10 bp 分辨率，两个生物学重复（rep1 / rep2）；
- 已知结构清单 `structures.csv`，字段含 type、chrom、start、end、center、length_bp；
- （可用，需自行查找下载）基因组注释 `NC_000913.3.gff`。

输出

- 候选新结构清单（CSV）：每条记录含染色体、起止坐标、中心位置、长度、所属结构簇、跨重复复现性指标（如两个重复 O/E 矩阵上三角部分的相关系数）及与已知结构的区分说明；
- 每个候选的归一化热图（PNG，统一色标与渲染协议）。

完成度的最低要求是：能正确复现已知的宏观结构域或已知结构以证明流程无误即可。

任务三：接触频率以及结构分布可视化（10分）

任务目标。本任务为纯可视化任务，不涉及模型训练，目标是根据接触矩阵与注释数据绘制基因组浏览器风格的多轨道图。

任务要求。横轴为基因组位置（bp），每张图覆盖固定区间（如 10000 bp），按序绘制多张以覆盖整个基因组；纵轴为各位点的接触强度（为了可读性可以取平方根）。图中叠加多个（至少三个，越多越好）实验条件（如 WT、HNS 突变、44°C）的接触强度曲线。图层自上而下分为四个面板：顶部面板绘制各条件的接触强度曲线（不同颜色）与灰色填充背景（表示基线或均值）；中间面板绘制多条件平均后的覆盖度或信号强度；其下为基因轨道，用蓝色方块标出基因的位置与范围；最底部为结构轨道，用橙色方块标出 CHIN、OPCID 的区间并标注名称。所有面板共享同一 X 轴，实现可用 matplotlib（配合 gridspec 设置 sharex）或 pyGenomeTracks。

任务的输入与产出如下：


输入

- 多个实验条件的 Micro-C 接触矩阵（如 WT、HNS 突变、44°C）；
- 已知结构清单（CHIN、OPCID 区间与名称）。

输出

- 覆盖整个基因组的成组多轨道图（每张对应一个 10000 bp 区间）；
- 绘图脚本（可复现，区间与条件可参数化）；
- 图例与各轨道的标注说明。

若图能清晰展示不同条件接触强度的差异，并与基因、结构区间对齐，即可认为任务完成。



多轨道可视化示意图

6.2 选做任务（至少选其一完成：20分）

任务四：不同实验条件下的结构变化分析

任务目标。数据提供同一批细胞在若干种不同实验条件下的接触矩阵，每种条件改变一个因素，例如去除某种蛋白或加入某种药物。比较这些条件下的矩阵，可以判断结构在哪些条件下发生变化，从而推断它依赖什么。从数据角度看，这是一组带标签的多类别数据。

任务要求。分两个方向，二选一。方向一是条件判别：以若干种条件为类别，训练模型根据接触矩阵判断样本属于哪种条件，用准确率和混淆矩阵评价，混淆矩阵可以看出哪些条件难以区分。方向二是差异定位：把每种条件与对照配对，找出差异最大的区域，再与已知结构对应，说明该结构在哪种条件下发生变化。各条件的含义与样本名见 5.1 节的表，只需知道每种条件对应一种处理，不必了解其分子机制。

任务的输入与产出如下：

输入

- 若干种实验条件的接触矩阵（`.cool.gz`，含重复与对照）与野生型矩阵；
- 可选：已知结构清单 `structures.csv`，用于差异定位。

输出（依所选方向而定）

- 方向一（条件判别）：各条件的判别混淆矩阵与准确率（数值表 + 图）；
- 方向二（差异定位）：差异结构图谱（CSV），列出发生改变的结构及其坐标、实验条件、改变方向与程度，并附对应可视化热图；
- 两方向均需附简要说明，解释差异与条件之间的关系。

若分析能指出某一类结构在特定条件下消失或减弱，即说明该结构与该条件所干预的因子相关。

任务五：接触矩阵的超分辨重建

任务目标。Hi-C 数据数量众多，但分辨率通常限制在 0.5—1 kb；Micro-C 分辨率可达约 10 bp，但实验难度与成本较大，公开数据远少于 Hi-C。用低分辨率接触矩阵重建高分辨率（Micro-C 水平）矩阵是该方向的常见做法，已有 HiCPlus、HiCNN、hicGAN、DeepHiC、C2c 等工作。从深度学习角度看，这是超分辨（super-resolution）或图像到图像翻译问题：输入为低分辨率接触矩阵，目标是高分辨率矩阵。

任务要求。数据构造上，以高分辨率 Micro-C 矩阵为真值，通过合并 bin（降低分辨率）或下采样 reads（降低测序深度）生成低分辨率输入，构成输入-真值配对；也可使用公开的 Hi-C 数据作为输入，尝试 Hi-C 到 Micro-C 的跨模态重建。模型可用卷积网络、生成对抗网络或扩散模型。评价分两个层面：图像指标用 PSNR、SSIM 衡量重建质量，并以双线性或双三次插值作为基线；下游指标考察重建后的矩阵能否恢复已知结构（如 CHIN、OPCID）的形态与位置。

输入

- 低分辨率接触矩阵（由高分辨率 Micro-C 降采样得到，或自行下载公开的 Hi-C 数据）；
- 对应的高分辨率 Micro-C 矩阵，作为真值。


输出

- 超分辨模型及权重文件，附可复现的训练与评估脚本；
- 重建后的高分辨率矩阵；
- PSNR、SSIM 等重建指标与插值基线的对比（数值表 + 图）；
- 已知结构恢复情况的可视化与说明。

若重建矩阵在图像指标上明显优于插值基线，且能稳定恢复已知结构的形态，即可认为任务完成。

任务六：大肠杆菌染色体的三维形态重建

任务目标。接触矩阵记录全基因组位点两两之间的空间邻近程度，可据此重建整条染色体的三维形态。大肠杆菌染色体的整体特征已知，可用于检验重建结果。从深度学习角度看，这是由全基因组接触矩阵生成一组三维坐标的任务。



由矩阵数据得到染色体的三维空间分布示意图

任务要求。输入为全基因组 Micro-C 接触矩阵，按固定分辨率（如 1 kb 或 5 kb）分箱；输出为各 bin 的三维坐标。模型可用自编码器、图神经网络或扩散模型，并以多维标度（MDS）或距离几何优化等方法建立基线。训练目标需体现接触频率与空间距离的关系：接触越强，对应位点的空间距离越近。评价分两个层面：一致性，由生成的三维坐标反算距离或接触图，与原始矩阵比较（用相关系数或距离误差）；整体形态验证，重建结果是否复现已知的整体特征并以三维可视化呈现。

输入

- 全基因组 Micro-C 接触矩阵（按固定分辨率分箱，如 5 kb）；


输出

- 三维重建模型及权重文件，附可复现的训练脚本；
- 各 bin 的三维坐标，及由坐标反算的接触/距离图与原矩阵的一致性指标（数值表 + 图）；
- 染色体的三维可视化（含宏观结构域与关键位点的标注）；
- 与多维标度等基线方法的一致性对比。

若重建的三维形态能复现已知的整体特征，且在一致性指标上优于或接近基线方法，即可认为任务完成。

七、参考设计

参考设计采用双模态融合的技术路线。检测端以单类自编码器对局部接触矩阵做重建，用重建误差作为异常分数；识别端将局部矩阵渲染为热图，用预训练视觉模型（DINOv2）提取形状表征。两条路径的得分各自标准化后加权融合为 novelty 分数，据此对高分候选做联合嵌入聚类，并以跨生物学重复的复现性作为结构真伪的门槛。



参考设计流程示意图

该路线得到的参考结果是一个可复现的约 8 kb 的新结构候选簇，含 8 个成员，跨重复 O/E 相关性为 0.68，在 H-NS 缺失突变体中仍存在，表明其不依赖 H-NS。参考设计的局限在于：“新结构”的定义（簇成员数 ≥5 且不含已知结构）是人为约定，视觉模型对接触矩阵热图属域外输入，融合权重与降维对齐依赖人工设定。可据此改进，或改用概率生成模型等技术路线。

八、提交要求与评分标准

8.1 提交要求

每组提交三个文件，分别提交，不打成压缩包。代码须为 zip 压缩包，包含数据到结果的完整可运行流水线。讲解视频须使用 PPT 进行讲解，介绍问题定义、方法设计、实现与结果。实验报告须包含专门的“设计思路”章节，并涵盖问题定义、方法选择、对照实验、评价指标、结果表格与图表；由于目前没有统一的新结构认定标准，需自行给出“新结构”的判定依据，并在报告中将其写得清晰、合理、可操作。实验包中写清楚成员分工与贡献度（按百分比）。

文件命名标准：组号-姓名-学号

提交方式：组长向智慧树提交全部三个文件，组员仅需提交实验报告。

8.2 评分标准

维度	权重	评分要点
问题定义	15%	问题定义清晰、可操作、有依据
方法设计	25%	技术路线合理、选择有论证
实现与可复现	20%	流水线可运行、结果可复现
实验评价	25%	可重复性验证充分、论证严谨
解释与展示	15%	对结果进行充分展示，清晰明确的可视化

评分侧重“设计选择的论证”而非“性能数值”，直接照搬参考设计且无改进者不获高分。

8.3 加分项

在完成必做任务的基础上，以下内容可获得额外加分：结构发现结果的可视化清晰、美观、信息充分；利用大语言模型辅助新结构发现，如候选筛选、结果解读、自动注释等。

九、实验流程与进度安排

两周

十、参考资料

- Hi-C 技术综述（三维基因组与疾病机制）；
- Gavrilov AA, Nudler E, et al. Elementary 3D organization of active and silenced *E. coli*

genome. Nature, 2025, 645(8082): 1060. (OPCID / CHIN / CHID 术语与结构描述来源)

- cooler / cooltools 官方文档; PyTorch 官方教程; DINOv2 论文与开源实现。